

Forecast Auto-Adjustment

版本	修订信息	作者	日期
v1.0	创建文档	王晶	20201105

This is a research and implement of auto-adjustment for demand forecast in rolling predict.

在滚动预测中，根据前面滚动的情况或者在调度过程中根据新加入的真实值，去调整我们模型的预测值，以实现更高的精确度。可用在高峰预测等场景。主要是根据最近的误差表现来修正模型的预测值输出，作为新的输出。

1 Error as Feature

Original Model: $f: \hat{y}_t = f(X_t)$

New Model: $f: \hat{y}_t = f(X_t, e_{t-h}), e_{t-h} = y_{t-h} - \hat{y}_{t-h}$

The simplest method is to add error in previous rolling as feature in current rolling. The initial error could be set 1.

最直接的方式是把上一轮滚动的预测误差 e_{t-h} 作为下一轮的特征值加入。

2 Error Postprocess

Assume the fitted model is going to perform as previous. For example, if the model underestimates in $t-l$ predicting t , then it will do the same thing in t predicting $t+l$.

误差后处理方式。基于的假设是模型在该轮滚动的表现会延续上一轮的表现。比如上一轮滚动低估，该轮还是会低估。上一轮滚动高估，该轮还是会高估。

Let U be the event of model underestimation, O be the event of model overestimation.

让 U 是模型低估事件， O 为模型高估事件。

该方法假设： $P(U_t|U_{t-l}) = 1$ 和 $P(O_t|O_{t-l}) = 1$

Proof:

我们来证明这一假设是有一定合理性的。假如我们选用线性模型开始 $\hat{y} = X\theta$ 。

$$\begin{aligned}\hat{y}_{t-l} &= X_{t-l}\theta_{t-l} \\ \theta_{t-l} + \Delta\theta &= \theta_t \\ \Delta\theta &= -\alpha \frac{dloss_{t-l}}{dX_{t-l}} \\ \hat{y}_t &= X_t\theta_t = X_t(\theta_{t-l} + \Delta\theta)\end{aligned}$$

假设有个完美的模型 $y = X\theta_p$, $loss = |y - \hat{y}|$ 。如果 $\hat{y}_{t-l} \leq y_{t-l}$, 那么 $\theta_{t-l} \leq \theta_p$ （如果 $X_{t-l} > 0$, 表示 X_{t-l} 是正定矩阵），前面低估，我们要证明后面也很可能低估。

$$\Delta\theta = -\alpha \frac{d(y_{t-l} - X_{t-l}\theta_{t-l})}{dX_{t-l}} = \alpha\theta_{t-l}$$

$$\hat{y}_t = X_t(1 + \alpha)\theta_{t-l} \leq X_t(1 + \alpha)\theta_p = (1 + \alpha)y_t \quad \text{如果 } X_t > 0$$

如果 $\hat{y}_{t-l} > y_{t-l}$, 即 $\theta_{t-l} > \theta_p$ 。



$$\Delta\theta = -\alpha\theta_{t-l}$$

$$\hat{y}_t = X_t(1 - \alpha)\theta_{t-l} > X_t(1 - \alpha)\theta_p = (1 - \alpha)y_t$$

由于 α 比较小，我们可以近似不等式成立。 $P(\hat{y}_t \leq y_t | \hat{y}_{t-l} \leq y_{t-l}) \approx 1$, $P(\hat{y}_t > y_t | \hat{y}_{t-l} > y_{t-l}) \approx 1$ 。 α 越小，也就是梯度更新越慢，假设越有可能成立。上述基于线性模型的情况下成立，或者当 l 相对较小的时候，我们可以认为 y_{t-l} 和 y_t 之间的接近线性的。但该假设还不能推广到更通用的情况。

当特征矩阵 X_t 是正定矩阵，且 l 较小的时候，假设大概率成立。

该方法应用： $e_{t-l} = y_{t-l} - \hat{y}_{t-l}$, $\tilde{y}_t = \hat{y}_t + e_{t-l}$, \tilde{y}_t 为修正后的预测结果。在实际预测中会出现两种情况，造成看起来预测偏移延迟的情况。



总体准确率会比后面不低估也不高估更高，因为出现误差抵消。

为了可能减少这种情况，但不一定能够提升预测指标。我们引入趋势项进行规则调整。

- 如果训练集末尾趋势是增长的
 - 前面高估的部分沿用模型输出的原始结果，低估的部分进行误差修正
- 如果训练集末尾趋势是降低的
 - 前面低估的部分沿用模型输出的原始结果，高估的部分进行误差修正

3 Practice

我们选用Amazon，Google，Alibaba和JD四家公司两年的股票收盘价作为测试数据验证，原始预测，误差修正和误差趋势修正的对比结果。对比指标使用 $MAPE$ 和 CV 。模型采用线性模型，特征采用一系列事件序列特征。结果如下图

公司	原始预测平均 MAPE	原始预测 CV	误差修正平均 MAPE	误差修正 CV	误差趋势平均 MAPE	误差趋势 CV
Amazon	0.103	0.608	0.065	0.638	0.075	0.776
Google	0.076	0.650	0.057	0.766	0.066	0.768
Alibaba	0.082	0.450	0.048	0.407	0.069	0.436
JD	0.062	0.597	0.045	0.437	0.053	0.474

误差趋势的方式从效果表现来看没有误差修正好，但比原始预测要好一些。主要原因是如前所述，在计算平均MAPE和CV的时候，误差修正产生了更多的误差抵消。

示意图：

